

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Уральский федеральный университет
имени первого Президента России Б.Н. Ельцина»

Институт радиоэлектроники и информационных технологий – РТФ
Школа бакалавриата

ОТЧЕТ

По проекту
«Проведение исследований на стыке медицины и химии»
по дисциплине «Проектный практикум»

Заказчик: Фамилия И.О.
Куратор: Фамилия И.О.
ученая степень, ученое звание, должность
Студенты команды _____ 2 _____
Фамилия И.О.

Ильинский А.Д.
Ильинский А.Д.
Анкудинова П.А.

Екатеринбург, 2025

СОДЕРЖАНИЕ

Элементы оглавления не найдены.

ВВЕДЕНИЕ

1.1 Цель проекта

Целью проекта является проведение исследований с использованием машинного обучения, направленных на изучение экспрессии генов и их мутаций, а также выдвижение гипотез о маркерах рецидива рака предстательной железы.

Также ставится задача построения модели, которая на основе информации о пациенте будет возвращать вероятность рецидива в процентах, и написания клиент-серверного приложения для взаимодействия с моделью и удобного получения результата.

Проект включает в себя совместную работу с ХТИ. Планируется участие в семинарах по прикладной биологии и химии, что позволит углубить знания в данной области и создать модели машинного обучения для анализа данных.

1.2 Актуальность

Рак предстательной железы (РПЖ) является одним из самых распространенных онкологических заболеваний среди мужчин, занимая второе место по смертности от новообразований. С каждым годом все больше пациентов сталкиваются с диагнозом, требующим не только медицинского вмешательства, но и тщательного мониторинга состояния здоровья. Одной из ключевых задач в онкологии является прогнозирование вероятности рецидива заболевания, что критически важно для выбора оптимальной стратегии лечения и повышения шансов на успешное выздоровление.

1.3 Область применения продукта

Разработанный программный продукт будет использоваться в области исследования онкологии, в частности для работы с маркерами рецидивов рака предстательной железы. Ожидается, что инструмент окажет значительное

влияние на упрощение расшифровки генов из базы TCGA, благодаря клиент-серверному приложению.

1.4 Ожидаемые результаты и планируемые достижения

По завершении проекта ожидается получение значимых результатов, оформленных в виде ноутбуков Colab, содержащих сформулированные гипотезы и проведенный анализ данных. Эти результаты будут способствовать более глубокому пониманию механизмов развития РПЖ и помогут в разработке новых методов диагностики и лечения. Планируется также создание клиента для android и сервера. Андроид приложение будет написано на языке Kotlin и будет использовать compose UI. Серверная часть будет написана на языке Python с использованием FastAPI.

2 Основная часть

2.1 Описание работы каждого участника команды

Краткая характеристика ролей и обязанностей каждого члена команды.

Анкудинова Полина Андреевна:

- Исследователь
- ML-инженер
- Разработчик клиент-серверного приложения

Занималась изучением предметной области, поиском и анализом научных работ. В обязанности как ML-инженера входила подготовка и обработка данных, выбор и настройка моделей, их обучение и оценка, а также интеграция ML-решений в рабочий процесс проекта.

Занималась проектированием и реализацией архитектуры приложения, включая разработку как клиентской, так и серверной частей. Обеспечила корректное взаимодействие между пользовательским интерфейсом и серверной логикой, а также отвечала за стабильность работы системы.

2.2 Анализ требований заказчика и пользователей

В рамках проекта было проведено исследование генетических мутаций и биомаркеров, связанных с раком предстательной железы. Основные требования заказчика заключаются в необходимости выявления маркеров, которые будут сигнализировать о рецидиве. Для достижения этой цели был составлен план действий (backlog), включающий следующие этапы:

- Сбор и анализ существующих данных о генетических мутациях и биомаркерах.
- Посещение семинаров ХТИ для углубления знаний в области биологии и химии.

- Внедрение лучших моделей машинного обучения для анализа данных в приложение.

2.3 Анализ и сопоставление аналогов разрабатываемого продукта

В ходе анализа существующих решений было выявлено несколько аналогичных программных продуктов, которые также направлены на изучение генетических факторов рака. Например, исследования, представленные в статье "Genomic landscape of prostate cancer".

Также важно отметить, что ключевая цель, которая стояла перед нами, — это в первую очередь исследование, а не разработка программного продукта как такового. Основной акцент был сделан на изучение особенностей обработки и анализа геномных данных, а также на выявление наиболее эффективных методов машинного обучения для решения поставленной задачи.

В рамках проекта была разработана и систематизирована собственная база знаний, посвящённая раку предстательной железы (РПЖ). Основная задача этой базы — собрать и структурировать актуальную медицинскую, молекулярно-биологическую и исследовательскую информацию, необходимую для понимания патогенеза, диагностики, лечения и прогноза данного заболевания.

Структура базы знаний включает следующие разделы:

- а) Общие сведения о раке предстательной железы
- б) Анатомия и функции простаты
- в) Диагностика и классификация
- г) Методы диагностики
- д) Прогноз и выживаемость
- е) Лечение
- ж) Исследования и биомаркеры
- з) Статистика и тенденции

и) Инструменты и технологии

База знаний служит основой для анализа геномных данных пациентов, обеспечивает понимание контекста для интерпретации результатов моделирования и формирует фундамент для выдвижения новых гипотез о биомаркерах РПЖ. Она объединяет не только клиническую и молекулярную информацию, но и современные исследовательские методики, что позволяет сопоставлять результаты машинного обучения с известными паттернами заболевания и повышать точность прогнозирования рецидивов.

The screenshot shows the 'Knowledge base BIO' interface. On the left, a sidebar lists categories such as 'Общие сведения', 'Рак предстательной железы', 'Лечение', 'Название команды', and 'Поддержка'. The main area displays 'Популярные темы' (Popular topics) under several headings: 'Общие сведения о раке', 'Рак предстательной железы', 'Лечение', 'Статистика и данные по раку предстательной железы', 'Название команды', and 'Поддержка'. Each topic is accompanied by a list of links. The top of the page includes a header with navigation icons and a search bar.

Рисунок 1 – База знаний проекта

Таблица 1 – Методы получения данных для исследования вероятности рецидива РПЖ

Метод исследования	Легко реализовать для исследования в университете	Время выполнения	Цена исследования (руб)	Точность анализа	Безопасно для пациентов	Доступность
Иммуногистохимический анализ (антитела к AT2-R) ¹	✗	3-7 рабочих дней	4 000	✓	✓	✓
Определение уровня ПСА ²	✗	1-2 часа	570	✓ ✗	✓	✓
Трансректальное ультразвуковое исследование (ТРУЗИ) ³	✗	30-60 минут	3 000	✓ ✗	✓	✓
Мультифокальная биопсия ⁴	✗	1-2 дня	6 700	✓	✓ ✗ (процедура инвазивная, возможны осложнения)	✓
Магнитно-резонансная томография (МРТ) ⁵	✗	1-2 дня	4 200	✓	✓	✓ ✗ (есть не во всех регионах)
Использование существующих датасетов для анализа данных о рецидиве РПЖ	✓	Зависит от объема данных, обычно от нескольких часов до нескольких дней	Бесплатно	✓ ✗	✓	✓ ✗ (варьируется в зависимости от источника данных)

Таблица 2 – Методы прогнозирования рецидива РПЖ

Метод прогнозирования	Легко реализовать для исследования в университете	Быстрое время выполнения	Высокая точность прогнозирования	Безопасность для пациентов	Доступность
Биохимический анализ (уровень ПСА, скорость прироста)	✗	✓	✓ ✗ (высокий уровень ПСА не всегда указывает на рак)	✓ (требует только образец крови)	✓
Клинические испытания ⁷	✗	✗	✓	✓ ✗ (в зависимости от исследуемого вмешательства)	✓ ✗
Модели машинного обучения (на основе данных маркеров) ⁸	✓ ✗	✓ ✗	Зависит от модели	✓	✓ ✗ (требуют наличия больших объемов данных)

2.4 Обзор архитектуры программного продукта

Архитектура программного продукта включает в себя несколько основных компонентов:

1) Модель машинного обучения. В ходе тестирования трех моделей (LogisticRegression, RandomForestClassifier, GradientBoostingClassifier) была выбрана наилучшая - GradientBoostingClassifier.

2) Серверная часть представляет собой Google Colab, в котором хранится сервер, написанный с использованием FastAPI и ngrok.

3) Клиент, написанный для Android, на языке Kotlin, Compose UI.

В качестве ключевого модуля используется модель машинного обучения, обученная на подготовленных геномных данных пациентов.

Эксперименты с моделями, включая логистическую регрессию, случайный лес и градиентный бустинг, проводились с использованием кросс-валидации с 5 фолдами. Основные метрики показали следующие результаты: точность (Accuracy) составила 85%, точность положительных предсказаний (Precision) – 82%, полнота (Recall) – 78%, а F1-score – 80%. Матрица ошибок продемонстрировала улучшение точности классификации для случаев с рецидивом, а среднее значение кросс-валидации модели составило 0.912.

Модель случайного леса показала наилучшие результаты для задач классификации с точностью 85%, в то время как логистическая регрессия оказалась наименее точной (78%). Итоговая модель успешно удовлетворяет требованиям проекта и демонстрирует хорошую обобщающую способность на новых данных, что подтверждает ее предсказательную эффективность и стабильность.




Рисунок 2 – Общий график метрик




Рисунок 3 – Общий график метрик после построения моделей




Рисунок 4 – Сравнение метрик для различных алгоритмов




Рисунок 5 – Сравнительные ROC-кривые для всех моделей




Рисунок 6 – Кросс-валидация: значения точности по фолдам модели GradientBoostingClassifier

Серверная часть реализована с использованием FastAPI — современного фреймворка для создания RESTful API на Python. Сервер размещен в облачной среде Google Colab, что позволяет быстро развернуть и протестировать приложение. Для обеспечения внешнего доступа к серверу используется ngrok, позволяющий предоставить публичный URL для взаимодействия с клиентской

частью.

Сервер обрабатывает запросы от клиента, выполняет предсказания с помощью обученной модели и возвращает результаты клиенту. Взаимодействие между клиентом и сервером осуществляется через три эндпоинта, что обеспечивает простоту интеграции и поддержки.

```
[ ] # =====
# 6. Запуск сервера
# =====
print("\n6. Запуск сервера")
if __name__ == "__main__":
    nest_asyncio.apply()
    public_url = ngrok.connect(8000).public_url
    print("\n🔥 Сервер доступен по URL:", public_url)
    print("📘 Документация API:", f"{public_url}/docs\n")
    uvicorn.run(app, host="0.0.0.0", port=8000)
```

→ 6. Запуск сервера

🔥 Сервер доступен по URL: <https://a699-34-73-147-116.ngrok-free.app>
📘 Документация API: <https://a699-34-73-147-116.ngrok-free.app/docs>

```
INFO:     Started server process [279]
INFO:     Waiting for application startup.
INFO:     Application startup complete.
INFO:     Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
INFO:     149.154.161.245:0 - "GET / HTTP/1.1" 404 Not Found
ERROR:asyncio:Task exception was never retrieved
future: <Task finished name='Task-98' coro=<Server.serve() done, defined at
Traceback (most recent call last):
```

Рисунок 7 – Код запуска сервера

Клиентское приложение разработано для платформы Android на языке Kotlin с использованием Compose UI. Приложение имеет одну activity и три экрана, что обеспечивает интуитивно понятный и удобный интерфейс для пользователя.

Клиент отправляет запросы к серверу, получает результаты анализа и отображает их пользователю. Взаимодействие с сервером реализовано через REST API.




Рисунок 8 – UI Android-приложения. Три экрана



TCGA

Рисунок 9 – Иконка приложения

Архитектура приложения является монолитной: все основные компоненты (интерфейс пользователя, бизнес-логика, база данных, модель машинного обучения) объединены в единую систему, развернутую на сервере.

Преимущества монолитной архитектуры для данного проекта:

- Простота разработки и развертывания — все компоненты находятся в одном месте, что упрощает управление и тестирование.
- Минимальные затраты на инфраструктуру — для запуска приложения достаточно одного сервера.
- Легкость в отладке и тестировании — все модули доступны для совместного тестирования, что снижает вероятность ошибок интеграции.

Недостатки монолитной архитектуры, такие как сложность масштабирования и потенциальные проблемы при значительном увеличении функциональности, не являются критичными для текущего этапа проекта, поскольку масштаб приложения остается небольшим.

Краткое описание взаимодействия компонентов

- а) Клиент (Android приложение) отправляет запросы на сервер.

б) Сервер (FastAPI, Google Colab, ngrok) обрабатывает запросы, выполняет анализ с помощью модели машинного обучения и возвращает результаты клиенту.

в) Модель машинного обучения (GradientBoostingClassifier) используется для прогнозирования на основе геномных данных.

2.5 Описание методологии разработки и процесса тестирования

Методология разработки основана на использовании Agile-подхода, что позволяет гибко реагировать на изменения требований и обеспечивать постоянное взаимодействие с заказчиком. Процесс разработки включает следующие этапы:

- Определение требований и создание backlog.
- Проведение спринтов для реализации функционала.
- Тестирование приложения на промежуточных этапах с помощью ручного тестирования.

2.6 Планирование деятельности и распределение задач

Планирование деятельности осуществлялось с помощью инструментов управления проектом – Trello. Задачи распределяются между участниками команды на основе их компетенций и текущей загрузки.

ЗАКЛЮЧЕНИЕ

В ходе выполнения проекта была достигнута основная цель — проведение исследования по выявлению маркеров, сигнализирующих о высокой вероятности рецидива рака предстательной железы (РПЖ) с применением методов машинного обучения. Разработанный программный продукт соответствует поставленным требованиям: реализована обработка и анализ геномных данных, построена и протестирована эффективная модель прогнозирования, создана база знаний по РПЖ, а также обеспечено удобное взаимодействие между клиентской и серверной частью.

Качество программного продукта подтверждается результатами тестирования: итоговая модель GradientBoostingClassifier показала высокие значения точности и устойчивости на новых данных, а клиент-серверное приложение стабильно функционирует при передаче и обработке запросов. В ходе тестирования были выявлены и устранены незначительные ошибки, не влияющие на общую работоспособность системы.

Проект обладает потенциалом для дальнейшего развития. В качестве направлений для улучшения можно выделить: расширение базы знаний, интеграцию новых источников данных, внедрение дополнительных методов визуализации результатов, а также оптимизацию архитектуры для повышения масштабируемости. Полученные результаты могут быть использованы для дальнейших исследований в области биоинформатики и медицинской диагностики.


СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. The Cancer Genome Atlas Program (TCGA). National Cancer Institute. URL: <https://www.cancer.gov/tcga>
2. Cancer Genome Atlas Research Network. The Molecular Taxonomy of Primary Prostate Cancer. *Cell*. 2015;163(4):1011-1025.
3. Rawla P. Epidemiology of Prostate Cancer. *World J Oncol*. 2019;10(2):63-89.
4. Справочные материалы проекта: <https://bio-informatics.atlassian.net/>
5. Воробьев, А. И. Рак предстательной железы: современные подходы к диагностике и лечению. *Практическая онкология*. 2021;22(2):45-53.
6. National Comprehensive Cancer Network (NCCN) Guidelines: Prostate Cancer. URL: <https://www.nccn.org/guidelines/guidelines-detail?category=1&id=1459>
7. Bray F. et al. Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA Cancer J Clin*. 2021;71(3):209-249.
8. GLOBOCAN 2020: Prostate Cancer Fact Sheet. International Agency for Research on Cancer. URL: <https://gco.iarc.fr/today/data/factsheets/cancers/27-Prostate-fact-sheet.pdf>
9. Справочные материалы и публикации на платформе bio-informatics.atlassian.net
10. Pedregosa F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*. 2011;12:2825-2830.
11. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
12. Documentation: FastAPI. URL: <https://fastapi.tiangolo.com/>
13. Documentation: Google Colab. URL: <https://colab.research.google.com/>
14. Documentation: Android Developers. Jetpack Compose. URL: <https://developer.android.com/jetpack/compose>

15. Documentation: ngrok. URL: <https://ngrok.com/docs>
16. Справочник по биоинформатике / Под ред. С.А. Литвинова. — М.: Наука, 2018. — 512 с.
17. Власов, В.В. Биоинформатика: основы и приложения. — СПб.: БХВ-Петербург, 2020. — 432 с.
18. Кузнецов, С.Г. Современные методы машинного обучения для анализа медицинских данных. — М.: Физматлит, 2021. — 312 с.

ПРИЛОЖЕНИЕ А

ПРИЛОЖЕНИЕ ВAndroid-приложение. Экран ввода адреса сервера



ПРИЛОЖЕНИЕ С ПРИЛОЖЕНИЕ ДМатериалы

https://taplink.cc/bioinf_gen

ПРИЛОЖЕНИЕ Е

ПРИЛОЖЕНИЕ ФГитхаб

<https://github.com/orgs/bio-inf-pp/repositories>

ПРИЛОЖЕНИЕ G

ПРИЛОЖЕНИЕ НБилд приложения

https://github.com/bio-inf-pp/android_bio-inf/releases/tag/%D0%BA%D1%823