

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Уральский федеральный университет
имени первого Президента России Б. Н. Ельцина»

Институт радиоэлектроники и информационных технологий – РТФ
Школа бакалавриата

ОТЧЕТ
ПО ПРОЕКТНОЙ РАБОТЕ:
«Разработка образовательных материалов и
проектов в сфере Data Science»
Дисциплина: «Проектный практикум»

Куратор: Ильинский А. Д.

Студент команды «Фермер»

Баталов К. Д.

Екатеринбург, 2025

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 Выполнение лабораторных работ.....	5
1.1 Выполнение лабораторной работы №1	5
1.2 Выполнение лабораторной работы №2	6
1.3 Выполнение лабораторной работы №3	8
1.4 Выполнение лабораторной работы №4	11
2 Выполнение итогового задания №1	13
2.1 Исследовательский анализ (EDA)	13
2.2 Feature Engineering	15
2.3 Обучение моделей.....	17
3 Выполнение итогового задания №2	20
3.1 Исследовательский анализ (EDA)	20
3.2 Feature Engineering	23
3.3 Обучение моделей.....	25
ЗАКЛЮЧЕНИЕ	27
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	29
ПРИЛОЖЕНИЕ А (справочное) Графики распределения числовых данных в итоговом задании №1	30
ПРИЛОЖЕНИЕ Б (справочное) Боксплоты числовых данных в итоговом задании №1.....	31
ПРИЛОЖЕНИЕ В (справочное) Графики распределения числовых данных в итоговом задании №2	32
ПРИЛОЖЕНИЕ Г (справочное) Боксплоты числовых данных в итоговом задании №2.....	33
ПРИЛОЖЕНИЕ Д (справочное) Боксплоты категориальных данных в итоговом задании №2	34

ВВЕДЕНИЕ

Работа в рамках образовательного трека по Data Science представляет собой выполнение четырех лабораторных работ и двух итоговых заданий, направленных на формирование ключевых практических навыков в этой области.

Цель: освоение инструментов и методов Data Science через решение прикладных задач.

Задачи:

- изучение теоретических основ Data Science;
- получение практического навыка работы с функциями (лабораторная работа №1);
- получение практического навыка корреляционного анализа (лабораторная работа №2);
- получение практического навыка работы с линейными моделями (лабораторная работа №3);
- получение практического навыка работы с ансамблями и полносвязанными нейронными сетями (лабораторная работа №4);
- создание предсказывающей модели-классификатора (итоговое задание №1);
- создание предсказывающей модели-регрессора (итоговое задание №2).

Актуальность обусловлена растущим спросом на специалистов в области Data Science. По данным Всемирного экономического форума сфера Data Science является одной из самых востребованных у работодателей [1]. Это делает критически важным получение не только теоретических знаний, но и практического опыта работы с реальными данными и алгоритмами.

Выполненные работы в рамках образовательного трека позволят обрести базовые практические навыки и создадут необходимый фундамент для дальнейшего развития в сфере.

Ожидаемые результаты:

- успешное выполнение всех лабораторных работ с применением изученных методов;
- создание рабочих моделей классификации и регрессии, демонстрирующих понимание ключевых этапов Data Science;
- формирование базы для дальнейшего углубленного изучения машинного обучения и анализа данных.

1 Выполнение лабораторных работ

1.1 Выполнение лабораторной работы №1

В рамках данной лабораторной работы были выполнены практические задания по освоению ключевых методов обработки данных с использованием библиотеки NumPy и базовых алгоритмов Python. Работа проводилась в два этапа: первый был посвящен матричным операциям с применением NumPy, второй - реализации фундаментальных алгоритмов обработки данных на чистом Python [2].

Основное внимание в первой части работы уделялось освоению возможностей библиотеки NumPy для эффективной работы с многомерными массивами. Была разработана функция `sum_prod(X, V)`, вычисляющая сумму произведений матриц на векторы. Особенностью реализации стало использование векторизованных операций через `np.dot()`, что обеспечило высокую производительность вычислений. Функция включает проверку корректности входных данных и протестирована для матриц различных размерностей (2×2 , 3×3 , 4×4).

Важным аспектом работы стала реализация функции бинаризации матрицы `binarize(M, threshold)`, которая преобразует исходную матрицу в бинарную форму относительно заданного порога. Алгоритм предусматривает обработку различных случаев, включая отрицательные и нулевые значения, и использует оптимизированные операции NumPy. Также были созданы функции `unique_rows()` и `unique_columns()` для поиска уникальных строк и столбцов матрицы соответственно, с применением эффективных методов библиотеки NumPy.

Во второй части работы реализован набор базовых алгоритмов для обработки данных. Среди них:

- a) функция `vowel_counter()` для подсчета гласных букв в строке с учетом регистра;
- b) алгоритм проверки уникальности символов `uniq_string()` с использованием множеств;
- c) эффективная реализация подсчета единичных битов `count_bits()` через побитовые операции;
- d) функция `magic()` для итеративного перемножения цифр числа;
- e) вычисление среднеквадратического отклонения `mse()`;
- f) алгоритм разложения на простые множители `prime_factors()` с форматированным выводом.

Все разработанные функции сопровождались комплексом модульных тестов, обеспечивающих проверку:

- стандартных случаев использования;
- граничных условий (пустые входные данные, минимальные/максимальные значения);
- некорректных входных данных.

Тестирование проводилось с использованием `pytest`, что позволило автоматизировать процесс проверки и гарантировать надежность реализаций.

В результате выполнения работы были получены или закреплены следующие практические навыки:

- работа с многомерными массивами в NumPy;
- реализация базовых алгоритмов обработки данных;
- написание модульных тестов;
- обработка различных типов входных данных.

1.2 Выполнение лабораторной работы №2

В ходе выполнения данной лабораторной работы были освоены ключевые методы обработки и анализа данных с использованием библиотеки Pandas,

а также проведен комплексный корреляционный анализ. Работа состояла из двух взаимосвязанных частей, каждая из которых была направлена на формирование конкретных практических навыков в области Data Science [3].

Первая часть работы была посвящена изучению функциональных возможностей библиотеки Pandas на примере анализа датасета "Titanic". Основное внимание уделялось следующим аспектам:

1) загрузка и первичный анализ данных:

- a) освоена методика чтения CSV-файлов с помощью `pd.read_csv();`
- b) проведен предварительный анализ структуры данных через методы `head()`, `info()` и `describe()`;
- c) изучены типы данных и общие характеристики набора данных.

2) обработка пропущенных значений:

- a) реализована комплексная проверка наличия пропусков `isna().sum();`
- b) отработаны различные стратегии обработки пропущенных данных - заполнение медианными/средними значениями (`fillna()`), удаление некритичных строк с пропусками (`dropna()`);
- c) проанализированы последствия применения разных подходов к очистке данных.

3) манипуляции с DataFrame:

- a) освоены методы выборки данных (индексация, `loc/iloc`);
- b) реализована фильтрация по сложным условиям;
- c) проведена сортировка данных по нескольким критериям (`sort_values()`);
- d) выполнена группировка и агрегация данных (`groupby()` с различными функциями агрегации).

Вторая часть работы была посвящена изучению методов корреляционного анализа на примере набора данных "Brain Size". В рамках этой части можно выделить следующие аспекты:

- 1) подготовка данных:
 - а) освоена загрузка данных с нестандартными разделителями (табуляция);
 - б) проведена предварительная обработка заголовков и структуры данных;
 - в) выполнена проверка целостности и согласованности данных.
- 2) корреляционный анализ:
 - а) рассчитана полная корреляционная матрица методом Пирсона;
 - б) проведен детальный анализ полученных корреляций: интерпретация диагональных значений (1.0), объяснение симметричности матрицы, выявление значимых взаимосвязей между переменными;
 - в) визуализированы наиболее интересные корреляционные пары.
- 3) интерпретация результатов:
 - а) сформулированы содержательные выводы о взаимосвязях между переменными;
 - б) оценена статистическая значимость обнаруженных корреляций;
 - в) определены направления для дальнейшего анализа.

В ходе выполнения работы были получены следующие результаты:

- практические навыки работы с реальными наборами данных;
- навыки работы с методами обработки и очистки данных;
- понимание принципов корреляционного анализа;
- опыт содержательной интерпретации результатов анализа.

1.3 Выполнение лабораторной работы №3

В ходе выполнения данной лабораторной работы были освоены основные принципы построения и обучения линейных моделей машинного обучения для задач регрессии и бинарной классификации с использованием градиентного спуска [4].

Первая часть работы была посвящена созданию базовой архитектуры линейной модели, реализации моделей регрессии и классификации, а также обучению разработанных моделей и проверке их работоспособности на реальных данных. Основное внимание уделялось следующим аспектам:

- 1) построение базовой линейной модели:
 - а) разработан универсальный класс для линейных моделей, обеспечивающий основу для последующей специализации;
 - б) реализована инициализация параметров модели: весов и смещения;
 - с) добавлен метод линейного предсказания на основе входных признаков.
- 2) реализация линейной регрессии:
 - а) создан подкласс, наследующий базовую модель и использующий в качестве функции потерь среднеквадратичную ошибку (MSE);
 - б) реализован алгоритм градиентного спуска для оптимизации параметров модели;
 - с) добавлены методы обучения и получения предсказаний.
- 3) реализация линейной классификации:
 - а) создан подкласс линейной модели для решения задачи бинарной классификации;
 - б) в качестве функции потерь использована бинарная кросс-энтропия;
 - с) добавлена сигмоидная функция для перевода линейного выхода в вероятность;
 - д) реализованы методы обучения и предсказания классов.

4) подготовка и предобработка данных:

- a) использованы два набора данных: Student Performance Dataset (для регрессии) и German Credit Data (для классификации);
- b) выполнена нормализация признаков и целевой переменной (в случае регрессии);
- c) осуществлено разделение выборок на обучающую и тестовую части для корректной оценки качества моделей.

5) обучение моделей и анализ процесса:

- a) реализован итеративный процесс обучения с помощью градиентного спуска;
- b) произведено отслеживание функции потерь на протяжении эпох обучения;
- c) выполнена визуализация процесса обучения с помощью графиков, демонстрирующих динамику снижения ошибки.

Вторая часть работы была посвящена экспериментам с базовыми моделями с целью увеличения их точности, главным образом за счет смены гиперпараметров. Удалось получить результат точности ROC-AUC = 0.79 для логистической регрессии с помощью подбора оптимальных гиперпараметров.

В ходе выполнения лабораторной работы были получены следующие результаты:

- приобретены практические навыки реализации базовых линейных моделей машинного обучения на языке программирования Python;
- освоены методы градиентной оптимизации и работа с функциями потерь;
- получен опыт предобработки данных и визуального анализа обучения моделей;
- выявлены направления дальнейшего улучшения моделей, включая подбор гиперпараметров, расширение признакового пространства и оценку качества на кросс-валидации.

1.4 Выполнение лабораторной работы №4

В ходе выполнения данной лабораторной работы была решена задача повышения качества классификации кредитоспособности клиентов на основе набора данных German Credit Data [5]. Основной целью являлось достижение как можно более высокого значения метрики ROC-AUC на тестовой выборке. Работа представляла собой практическое применение современных моделей машинного обучения и методов ансамблирования. Оценка качества выполнения задания напрямую зависела от достигнутого значения ROC-AUC на тестовых данных.

Работа включала в себя несколько последовательных этапов, направленных на построение, улучшение и комбинирование моделей классификации.

Первая часть работы была посвящена подготовке данных и построению базовых моделей. Основное внимание уделялось следующим аспектам:

- 1) подготовка и анализ данных:
 - a) загружен исходный датасет из файла german.csv;
 - b) данные были разделены на обучающую и тестовую выборки в пропорции 80/20;
 - c) выполнена визуализация распределения классов, позволившая оценить баланс выборки;
 - d) применено масштабирование признаков с использованием StandardScaler для повышения стабильности обучения моделей.
- 2) обучение базовых моделей классификации:
 - a) были построены три независимые модели: Random Forest Classifier, Gradient Boosting Classifier, Multilayer Perceptron (MLP);
 - b) модели обучались с использованием стандартных параметров, что позволило зафиксировать их начальную эффективность.

Вторая часть работы была направлена на улучшение качества предсказаний за счёт оптимизации и ансамблирования. В рамках этого этапа были выполнены следующие действия:

- 1) оптимизация гиперпараметров моделей:
 - а) для Random Forest увеличено количество деревьев и оптимизирована максимальная глубина;
 - б) для Gradient Boosting подобраны оптимальные значения learning_rate и количества итераций;
 - в) для MLP была изменена архитектура нейронной сети и параметры обучения, включая количество слоёв, количество нейронов и скорость обучения.
 - 2) ансамблирование моделей:
 - а) Voting Ensemble (взвешенное голосование): использованы все три базовые модели, применено мягкое голосование (soft voting), учитывающее вероятности; заданы веса моделей (2:2:1), отражающие их относительную точность;
 - б) Stacking Ensemble: использованы те же базовые модели, предсказывающие на первом уровне; в качестве мета-классификатора использована Logistic Regression.
- По итогу экспериментов наилучший показатель был получен при использовании Voting Ensemble, где значение ROC-AUC составило 0.7952.
- В ходе выполнения лабораторной работы были получены следующие результаты:
- приобретены навыки построения и настройки нескольких моделей классификации;
 - освоены методы предварительной обработки и масштабирования данных;
 - реализованы и протестированы методы ансамблирования, продемонстрировавшие своё преимущество перед одиночными моделями.

2 Выполнение итогового задания №1

Итоговое задание №1 представляло собой создание модели машинного обучения для определения выживаемости пассажира на Титанике [6]. Работа включала в себя EDA и ресерч-анализ. Были построены графики, применены инструменты EDA, проведен анализ каждого графика. Рассмотрена корреляция колонок с таргетом. Проводился Feature Engineering, после которого рассматривалась корреляция новых колонок с таргетом. Были созданы простые модели. Проведены эксперименты с моделями машинного обучения/глубокого обучения, по одной из каждого семейства - линейные, деревья, модификации градиентного бустинга , нейронные сети.

2.1 Исследовательский анализ (EDA)

Исследовательский анализ данных был необходим для комплексного понимания структуры данных. Первым делом была выведена основная информация о датасете, в которой сразу удалось выявить пропущенные значения в столбцах: Age (19.8%), Cabin (77.1%), Embarked (0.2%).

Произведено разделение на числовые и категориальные признаки, после чего для числовых признаков были построены гистограммы распределения (приложение А) и боксплоты (приложение Б). По графикам обнаружены выбросы в Fare, SibSp.

Была также построена тепловая карта корреляций всех числовых признаков (рисунок 1).



Рисунок 1 – Тепловая карта корреляций числовых признаков Titanic

На основе тепловой карты корреляций сделаны ключевые выводы:

- большинство коэффициентов корреляции находятся в диапазоне от -0.25 до 0.25;
- самая значимая положительная корреляция наблюдается между SibSp и Parch (0.41);
- самая значимая отрицательная корреляция наблюдается между Pclass и Fare (-0.55);
- отсутствие сильных корреляций с Fare: несмотря на интуитивные предположения, стоимость билета слабо коррелирует с другими числовыми признаками;
- наличие умеренных отрицательных корреляций нескольких переменных с Pclass.

Аналогичная тепловая карта была построена для оценки корреляций с таргетным признаком Survived (рисунок 2).




Рисунок 2 – Корреляции числовых признаков с Survived

Были сделаны выводы: умеренная отрицательная корреляция с классом билета (Pclass) (примерно -0.34) - пассажиры первого класса имели больше шансов выжить; слабая положительная корреляция с платой за проезд (Fare) (примерно 0.26) - более дорогие билеты связаны с большей выживаемостью.

2.2 Feature Engineering

В наборе данных Титаника были выполнены следующие шаги по созданию признаков для улучшения данных для моделирования:

1) обработка пропущенных значений:

- a) Cabin (Каюта): был создан новый бинарный признак Has_Cabin, который указывает, есть ли у пассажира каюта, так как в столбце Cabin было более 50% пропущенных значений;
- b) Age (Возраст): пропущенные значения в столбце Age были заполнены медианным возрастом пассажиров, сгруппированных по Pclass и Sex;
- c) Embarked (Порт посадки): пропущенные значения в столбце Embarked были заполнены наиболее часто встречающимся портом посадки.

2) создание признаков:

FamilySize (Размер семьи): был создан новый признак FamilySize путем суммирования SibSp (братья/сестры и супруги на борту) и Parch (родители/дети на борту) и добавления 1 для учета самого пассажира;

3) преобразование категориальных признаков в числовые:

- a) Sex (Пол): преобразован в числовые значения, где 'male' (мужчина) - 0, а 'female' (женщина) – 1;
- b) Embarked (Порт посадки): преобразован в числовые значения с помощью маппинга: 'S' - 0, 'C' - 1, и 'Q' - 2.

Эти шаги были направлены на улучшение качества набора данных и его подготовку для использования в моделях машинного обучения. Была построена еще одна корреляционная матрица признаков (рисунок 3).




Рисунок 3 – Корреляционная матрица признаков Titanic

Здесь уже обнаружились значительные корреляции таргетного признака Survived с другими признаками.

2.3 Обучение моделей

В процессе обучения моделей на наборе данных Титаника были выполнены следующие шаги:

- подготовка данных:
 - выделены признаки: Pclass, Sex, Age, Fare, Embarked, SibSp, Parch, Has_Cabin, FamilySize;
 - числовые признаки были масштабированы с использованием StandardScaler;

с) данные разделены на обучающую и тестовую выборки в соотношении 80/20.

2) обучение моделей:

а) использовались следующие модели: Логистическая регрессия, Дерево решений, Случайный лес, Градиентный бустинг, XGBoost, Нейронная сеть (MLP);

б) лучшая модель по тестовой выборке: Нейронная сеть с точностью accuracy = 0.8268.

3) оценка моделей:

а) нейронная сеть: точность на тестовой выборке 0.8268, средняя точность при кросс-валидации (5 фолдов) составила 0.8182 ± 0.0131 .

б) ансамбли: VotingClassifier показал точность на тестовой выборке 0.8492, а StackingClassifier — 0.8324; при кросс-валидации VotingClassifier имел среднюю точность 0.8305 ± 0.0207 , а StackingClassifier — 0.8316 ± 0.0258 .

Лучшая классическая модель для предсказания на тестовой выборке - нейронная сеть MLP с результатом accuracy на test = 0.8268 и средней accuracy 0.8182 ± 0.0131 при кросс-валидации (5 фолдов).

Базовые модели (логистическая регрессия, деревья, случайный лес, бустинг, XGBoost) показали среднюю точность на тестовой выборке в диапазоне 0.78–0.82).

Кросс-валидация (5 фолдов) показала, что средняя accuracy чуть ниже, чем на одном test-сплите, что ожидаемо и говорит о том, что модель не переобучается под конкретное разбиение. Разброс accuracy по фолдам связан с небольшим размером датасета и неравномерным распределением классов.

Ансамбли (Voting, Stacking) дают ощутимый прирост точности по сравнению с одиночными моделями. VotingClassifier accuracy на test = 0.8492, а при кросс-валидации (5 фолдов) VotingClassifier средний accuracy на test = 0.8305 ± 0.0207 . StackingClassifier Accuracy на test = 0.8324, при кросс-валидации (5 фолдов) StackingClassifier средний accuracy = 0.8316 ± 0.0258 .

Это подтверждает, что комбинация разных подходов позволяет чуть лучше обобщать паттерны в данных.

Нейронная сеть (MLP) иногда не успевает сойтись за 1000 эпох, но даже в этом случае её качество сопоставимо с классическими моделями.

3 Выполнение итогового задания №2

Итоговое задание №2 представляло собой создание модели машинного обучения для определения популярности трека в Spotify [7]. Работа включала в себя EDA и ресерч-анализ. Были построены графики, применены инструменты EDA, проведен анализ каждого графика. Рассмотрена корреляция колонок с таргетом. Проводился Feature Engineering, после которого рассматривалась корреляция новых колонок с таргетом. Были созданы простые модели регрессии и проведена оценка точности моделей на представленном датасете.

3.1 Исследовательский анализ (EDA)

Как и в прошлом задании, исследовательский анализ данных необходим для комплексного понимания структуры данных. При первичном осмотре удалось выявить 1 строку с пустыми значениями в некоторых столбцах, ее пришлось удалить. Далее признаки были разделены на числовые и категориальные.

Для числовых признаков построены гистограммы (приложение В) и боксплоты (приложение Г). Также создана тепловая карта корреляций всех числовых признаков (рисунок 4).




Рисунок 4 – Тепловая карта корреляций числовых признаков Spotify

По тепловой карте был сделан вывод о том, что Popularity (целевая переменная очень слабо коррелирует со всеми числовыми признаками (< 0.1)

Для категориальных признаков построены боксплоты (приложение Д) и отдельно для жанров и артистов созданы гистограммы (рисунок 5, рисунок 6).




Рисунок 5 – Жанры по популярности




Рисунок 6 – Актисты(исполнители) по популярности

Большинство категориальных признаков (mode, explicit, key, time_signature) оказывали слабое влияние на популярность — различия медиан минимальны. Жанр (track_genre) — признак, где различия в популярности

между категориями выражены явно. В Artists (исполнители) различия тоже выражены явно, но с этим столбцом сложно работать, поскольку есть совместные песни, а также много аномалий.

3.2 Feature Engineering

Жанры были сгруппированы в более широкие категории, такие как электронная музыка, поп, рок, хип-хоп, джаз/блуз, классическая музыка, латино, мировая музыка, регги, настроенная музыка, специфические жанры и кантри. Это помогает уменьшить размерность признаков, связанных с жанрами, и охватывает более широкие музыкальные стили.

Темп был разделен на категории: медленный, средний, быстрый и очень быстрый. Эта категоризация основана на наблюдаемых пиках в распределении темпа, что позволяет более структурированно анализировать эффекты, связанные с темпом.

Был создан бинарный признак `is_extreme_tempo`, указывающий, находится ли темп трека в верхних или нижних 10% распределения темпа. Это может помочь выявить треки с необычными характеристиками темпа.

Был введен новый признак `features_balance`, измеряющий баланс между энергией, танцевальностью и валентностью. Этот признак отражает гармонию между этими атрибутами, что может коррелировать с популярностью трека.

Логарифмические преобразования были применены к `speechiness` и `instrumentalness` для обработки скошенных распределений и стабилизации дисперсии. Категориальные признаки, такие как `key`, `time_signature`, `genre_category`, `tempo_bin` и `duration_category`, были закодированы методом one-hot для преобразования их в формат, подходящий для моделей машинного обучения.

Выбросы в duration_min, loudness и tempo были удалены с использованием метода IQR, чтобы гарантировать, что экстремальные значения не исказяют обучение модели.

Были применены различные методы масштабирования:

- StandardScaler для нормально распределенных признаков, таких как энергия, танцевальность и валентность;
- RobustScaler для признаков с выбросами, таких как громкость, темп и длительность;
- MinMaxScaler для признаков, которые нужно привести к диапазону [0,1], таких как speechiness_log и instrumentalness_log.

Для оценки преобразований был построен график корреляции новых признаков с популярностью треков (рисунок 7).




Рисунок 7 – Корреляция новых признаков с popularity

Корреляции с популярностью треков по-прежнему слабые, но заметна корреляция с некоторыми жанрами (например, корреляция с категорией поп).

3.3 Обучение моделей

В процессе обучения моделей на наборе данных Spotify были выполнены следующие шаги:

- 1) подготовка данных:
 - a) выделен ключевой признак popularity;
 - b) выделены все остальные признаки для предсказания;
 - c) данные разделены на обучающую и тестовую выборки в соотношении 80/20.
- 2) обучение моделей:
 - a) использовались следующие модели: Линейная регрессия, Градиентный бустинг, XGBoost, KNN, Случайный лес, MLP;
 - b) лучшая модель по тестовой выборке: Случайный лес со средней квадратической ошибкой RMSE = 16.5319.

После кросс-валидации из 5 фолдов модель Случайного леса показала среднее $RMSE = 16.4202 \pm 0.1344$. Для наглядности был построен график предсказанных и настоящих значений популярности (рисунок 8).



Рисунок 8 – График настоящие vs предсказанные значения

Наглядно видно, что модель не идеальна - в области маленьких значений наибольшие проблемы. Но в целом, удалось добиться приемлемых результатов предсказания.

ЗАКЛЮЧЕНИЕ

В ходе выполнения проектной работы были разработаны и протестированы модели машинного обучения для решения задач классификации (прогнозирование выживаемости пассажиров Титаника) и регрессии (предсказание популярности треков в Spotify). Результаты работы демонстрируют соответствие поставленным целям, однако выявлены аспекты, требующие доработки и оптимизации.

Оценка соответствия требованиям:

1) лабораторные работы:

а) освоены ключевые методы обработки данных (NumPy, Pandas), корреляционного анализа, построения линейных моделей и ансамблирования;

б) реализованные модели показали удовлетворительные результаты (например, ROC-AUC = 0.7952 для Voting Ensemble в лабораторной работе №4), что соответствует базовым требованиям к обучению;

с) однако в некоторых случаях (например, нейронные сети) наблюдалась нестабильность обучения, что указывает на необходимость более тщательного подбора гиперпараметров.

2) итоговые задания:

а) для задачи классификации (Титаник) наилучшая модель (MLP) достигла accuracy = 0.8268, а ансамбли (VotingClassifier) улучшили результат до 0.8492, это свидетельствует о корректной обработке данных и эффективном комбинировании моделей;

б) в задаче регрессии (Spotify) лучшая модель (Random Forest) показала RMSE = 16.53, что приемлемо, но указывает на ограниченную предсказательную силу из-за слабых корреляций признаков с целевой переменной.

Оценка качества и выявленные проблемы:

1) качество данных: в данных Spotify слабая корреляция признаков с популярностью ограничила точность моделей;

2) моделирование:

а) ансамблирование дало прирост точности, но требует больших вычислительных ресурсов;

б) нейронные сети показали нестабильность, особенно при недостаточном количестве эпох обучения.

3) интерпретируемость: линейные модели и деревья обеспечивают прозрачность решений, в отличие от MLP и ансамблей, что важно для задач, требующих объяснимости.

Проект успешно выполнен: все поставленные задачи решены, а модели демонстрируют достаточную работоспособность. Для улучшения результатов требуется еще больше экспериментировать с готовыми моделями и тщательнее работать с предоставленными данными в датасетах.


СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Высшая школа экономики: «Data Science». [Электронный ресурс]. URL : <https://studyonline.hse.ru/data-science> (дата обращения : 27.05.2025).
2. Репозиторий GitHub «lab1». [Электронный ресурс]. URL: <https://github.com/vvoyage/lab1> (дата обращения : 27.05.2025).
3. Репозиторий GitHub «lab2». [Электронный ресурс]. URL: <https://github.com/vvoyage/lab2> (дата обращения : 27.05.2025).
4. Репозиторий GitHub «lab3». [Электронный ресурс]. URL: <https://github.com/vvoyage/lab3> (дата обращения : 27.05.2025).
5. Репозиторий GitHub «lab4». [Электронный ресурс]. URL: <https://github.com/vvoyage/lab4> (дата обращения : 27.05.2025).
6. Репозиторий GitHub «titanic_contest». [Электронный ресурс]. URL: https://github.com/vvoyage/titanic_contest (дата обращения : 27.05.2025).
7. Репозиторий GitHub «spotify_contest». [Электронный ресурс]. URL: https://github.com/vvoyage/spotify_contest (дата обращения : 27.05.2025).

ПРИЛОЖЕНИЕ А

(справочное)


Графики распределения числовых данных в итоговом задании №1



ПРИЛОЖЕНИЕ Б


(справочное)

Боксплоты числовых данных в итоговом задании №1



ПРИЛОЖЕНИЕ В (справочное)


Графики распределения числовых данных в итоговом задании №2



ПРИЛОЖЕНИЕ Г

(справочное)

Боксплоты числовых данных в итоговом задании №2



ПРИЛОЖЕНИЕ Д

(справочное)

Боксплоты категориальных данных в итоговом задании №2

